Plano Executivo: Sistema de Análise e Ingestão de Processos Judiciais

Atualização do projeto: uma planilha viva por caso, com linha do tempo dos atos, cronologia conferida e medições de custo e tempo

1. O que fizemos

Construímos uma plataforma que recebe os **PDFs de processos judiciais** (eproc, PJe e autos digitalizados, inclusive volumes e partes de um mesmo processo), lê o conteúdo com **OCR** quando necessário e aplica os **prompts do analista** de cada tipo de processo para **preencher a planilha de relatório** do caso.

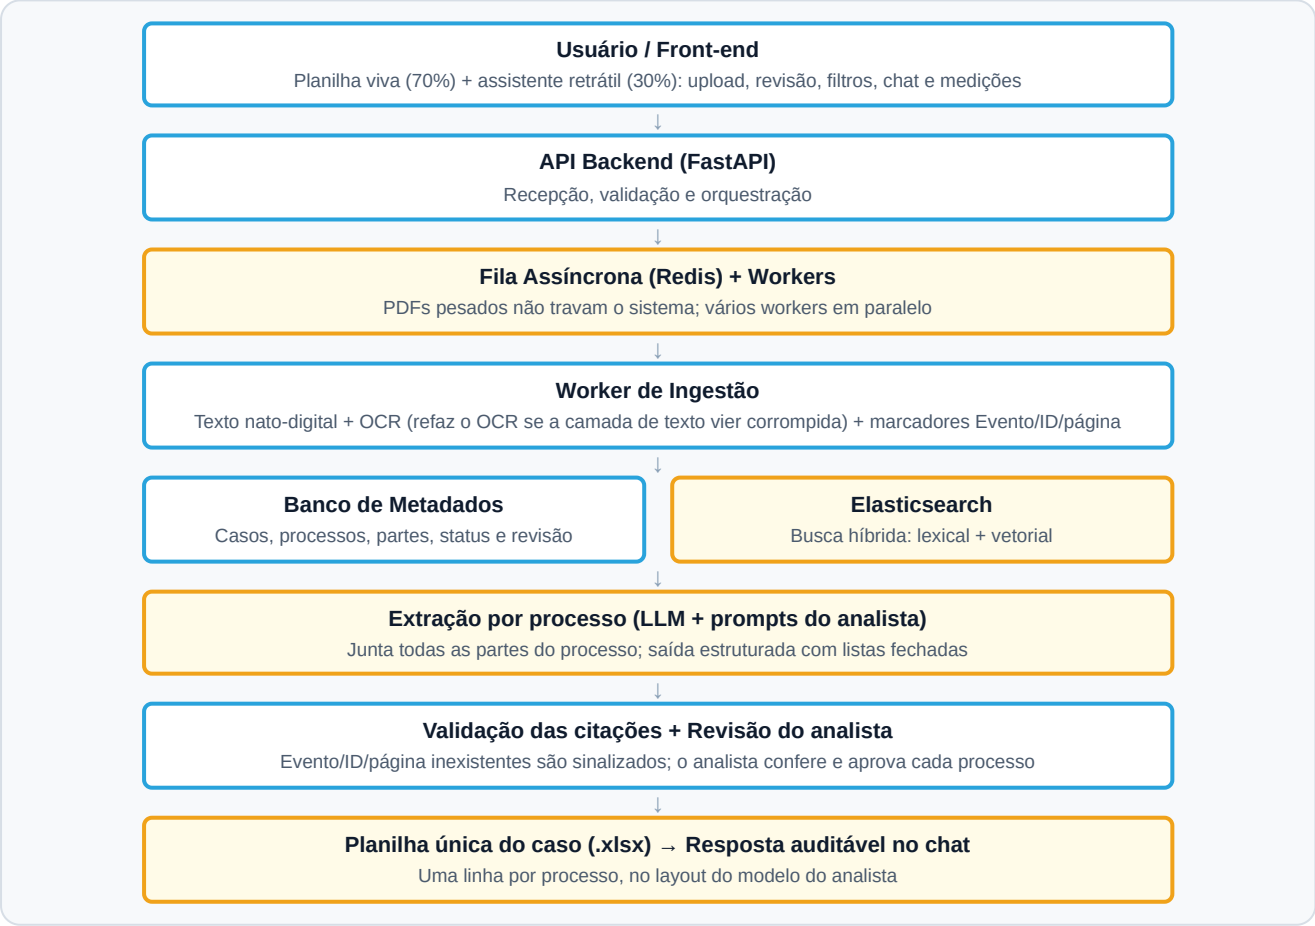
O analista escolhe o **tipo** (execução fiscal, embargos, apelação, agravo, outras ações) e o **sistema**; o prompt correto é aplicado automaticamente. Um **chatbot analítico** responde sobre o processo citando a origem exata.

2. O porquê

Hoje o fluxo é manual: baixar o processo, anexar a uma ferramenta de IA, colar o prompt, copiar o relatório e digitar célula a célula na planilha. Além de lento, a IA **confunde Evento (eproc) com ID (PJe)** e a página do ato com a página do PDF.

A solução **elimina a digitação**, monta as citações pelo código (não pelo modelo), **confere cada citação contra o PDF** e mantém o analista na decisão final com uma etapa de revisão.

3. Desenho da Arquitetura



4. Stack Tecnológica

Componente	Tecnologia Escolhida e Justificativa
Linguagem Core	**Python + FastAPI:** ecossistema de IA, PDFs e OCR; API simples e testável.
Mensageria	**Redis:** enfileira PDFs pesados e evita timeouts; execução também em memória para desenvolvimento.
Leitura e OCR	**PyMuPDF + Tesseract (português):** lê texto digital e refaz o OCR de páginas digitalizadas ou com texto corrompido.
Busca e Armazenamento	**Elasticsearch (busca híbrida):** similaridade semântica e busca exata por palavra-chave; SQLite para metadados.
Motor Cognitivo	**Google Gemini (AI Studio), com Anthropic como alternativa:** provedor intercambiável, saída em JSON restrito ao esquema de cada aba.
Planilha	**openpyxl:** gera o .xlsx com as abas e cabeçalhos do modelo (Relatório, Execuções Fiscais, Outras Ações, Embargos, Outros Bens, Alegações de Fraude).
Front-end	**HTML/CSS/JS no padrão visual gov.br:** sem dependências externas, simples de hospedar.

5. Resultado Esperado (Visão de Front-end)

O analista trabalha por caso (devedor ou grupo), e o sistema entrega em três frentes:

- **Automação de Planilhas:** envia os PDFs, escolhe o tipo, e o sistema monta **uma única planilha com uma linha por processo**. Volumes e partes do mesmo processo são juntados numa só análise.
- **Citações confiáveis:** eproc cita **Evento N, pg. P**; PJe cita **ID N, pg. P**. Toda citação é conferida com o PDF antes de chegar ao analista.
- **Revisão e Chatbot:** o analista aprova cada processo (linhas não revisadas saem destacadas) e pergunta, por exemplo, *"Existe valor bloqueado pelo Sisbajud?"*, com resposta e página de origem.

O resultado é a padronização do relatório e a redução do tempo de cada processo, sem retirar o analista da decisão.

6. Situação do Projeto e Próximos Passos

O que está pronto, o que foi validado e o que depende de validação com dados reais

Já implementado

- **Pronto** **Planilha do próprio analista como modelo:** o sistema lê as colunas e abas do .xlsx, preenche só células vazias e avisa sobre colunas que não reconhece (o cadastro do Mcfly foi substituído por isso).
- **Pronto** **Interface em tela única:** tabela editável (70%) e assistente retrátil (30%), tema claro/escuro, filtros, colunas e linhas redimensionáveis, janelas para textos longos e lista de corresponsáveis (Nome – CPF/CNPJ).
- **Pronto** **Ingestão assíncrona** com OCR (refeito quando o texto embutido vem corrompido), fila com recuperação de PDFs travados, reenvio e exclusão por PDF.
- **Pronto** **Linha do tempo do eproc** lida das páginas de separação (2º grau e 1ª instância): índice completo de eventos, texto integral só dos atos relevantes e cronologia conferida (datas corrigidas, ordem, eventos inexistentes apontados).
- **Pronto** **Linha do tempo do PJe** a partir do índice da capa e dos rodapés “Num. ID – Pág.”; autos digitalizados (Volume) tratados à parte. Validado com amostra real; falta testar com mais processos.
- **Pronto** **Medições**: tokens, páginas enviadas à IA, cortes, tempos de leitura/OCR e de IA, tentativas e espera por limite de uso.
- **Pronto** Integração com Gemini (AI Studio) com novas tentativas, modelo reserva e mensagens claras de erro; 80 testes automatizados.

Pendências e riscos

Item	Situação e ação
Qualidade com dados reais	**Em andamento.** Comparar a saída com os relatórios já feitos à mão em um lote de 20 a 30 processos (campos certos, citações válidas, cronologia completa).
Limite de uso do Google	**Em andamento.** O nível gratuito limita chamadas por dia e por minuto (e erros 503 em horários de pico). Para volume é preciso conta com faturamento e termos de dados definidos.
OCR em escala	**Em medição.** É a etapa mais lenta nos autos digitalizados; o tempo real aparece em Medições e orienta quantos workers usar.
Confidencialidade (LGPD)	**Atenção.** Não usar o nível gratuito com processos reais; confirmar nos termos da parceria que os dados não treinam modelos. Incluir login (SSO) e trilha de auditoria antes de expor o sistema.
Chave de acesso	**Atenção.** A chave da API foi exibida em tela durante os testes: deve ser revogada e recriada, e nunca versionada.

Plano sugerido

- **Fase 1 (piloto):** 20 a 30 processos reais variados; medir tempo, tokens e acerto contra o relatório manual.
- **Fase 2 (ajustes):** corrigir prompts, listas fechadas e regras com as divergências; decidir o modelo e o regime de custo.
- **Fase 3 (produção):** autenticação, auditoria, monitoramento de custo e tempo por processo.

7. Como escalar: Minas Gerais e, depois, o Brasil

Roteiro em etapas; cada etapa só começa quando a anterior mostra resultado medido

Etapa	Objetivo e entregas
0. Piloto (equipe atual)	Provar ganho com números: tempo por processo, % de campos corretos, citações válidas. Gera o “conjunto de referência” (processos já analisados à mão) usado em todas as etapas.
1. Minas Gerais	Login institucional, perfis por procuradoria, trilha de auditoria, banco e arquivos em infraestrutura gerenciada, vários workers, monitoramento, faturamento do modelo de IA e acordo de tratamento de dados.
2. Vários sistemas e tribunais	Um adaptador por sistema processual (eproc e PJe já feitos; mapear e-SAJ, Projudi e outros). A linha do tempo de cada sistema alimenta o mesmo motor de extração.
3. Brasil	Implantação por regiões/unidades, painel de custos e qualidade, biblioteca nacional de prompts versionados, suporte e treinamento.

Pontos de decisão para a direção

- **Onde rodar:** nuvem institucional ou infraestrutura própria, e qual provedor de IA com garantia de que os dados não treinam modelos.
- **Como medir sucesso:** horas poupadas por processo, taxa de correção pelo revisor e tempo de fila.
- **Quem mantém:** responsável técnico, dono dos prompts por tipo de ação e rotina de revisão de qualidade.

Os números de capacidade e custo serão calculados com as medições do piloto, não por estimativa.