GUIA DE ESTUDO, ESCALA E PORTFÓLIO

Sistema de Análise e Extração de Processos Judiciais

O que cada parte faz e por quê, como levar o projeto de Minas Gerais ao Brasil e como apresentá-lo como portfólio

- **1.** O sistema em um minuto
- **2.** Estudo das implementações (15 módulos, com “o que dizer”)
- **3.** Decisões de projeto e alternativas descartadas
- **4.** Como escalar: Minas Gerais e depois o Brasil
- **5.** Como apresentar como portfólio, usando IA, de forma pessoal e honesta
- **6.** Perguntas que você vai receber (e como responder)
- **7.** Glossário

> **Como usar:** leia a seção 2 abrindo o arquivo indicado em “Onde”. Para cada módulo, tente explicar com as suas palavras o que ele faz antes de ler a descrição. Os números de capacidade e custo são estimativas: troque-os pelas suas medições (tela Medições).

1. O sistema em um minuto

O analista da PGFN hoje abre o PDF do processo, lê, aplica o seu prompt numa ferramenta de IA e digita o resultado numa planilha. O sistema automatiza o caminho inteiro e mantém o analista como decisor.

PDFs do processo → **Fila + worker** → **Leitura + OCR** → **Linha do tempo (eproc / PJe)** → **IA com o prompt do analista** → **Conferência das citações** → **Planilha viva** → **Revisão** → **Exportar .xlsx**

Três ideias que sustentam tudo: (1) a IA só *interpreta*; tudo o que dá para calcular por regra (número do evento, data, ID, página) é feito por código, que não erra por "criatividade"; (2) toda resposta cita a origem e é conferida contra o PDF; (3) uma planilha por caso, uma linha por processo, no layout do próprio analista.

2. Estudo das implementações

Cada cartão segue o mesmo roteiro: **Problema** que resolve, **O que faz**, **Conceito** para aprender, **Onde** está no código e **Diga** (frase pronta para a apresentação).

1 API e banco de metadados

PROBLEMA	Algo precisa receber os PDFs, guardar o estado de cada processo e servir a tela.
O QUE FAZ	FastAPI expõe endpoints (casos, upload, planilha, revisão, chat, exportação). O SQLite guarda casos, processos, PDFs, resultados e status, com migrações automáticas de colunas.
CONCEITO	API REST, validação com Pydantic, migração de esquema, idempotência (o mesmo PDF, pelo hash sha256, não entra duas vezes).
ONDE	`app/main.py`, `app/db.py`, `app/schemas.py`
DIGA	"A API é fina: valida, grava e enfileira. O trabalho pesado nunca roda dentro da requisição."

2 Fila, worker e "vigia"

PROBLEMA	PDFs de centenas de páginas e chamadas de IA levam minutos; a tela não pode travar nem perder trabalho.
O QUE FAZ	A API põe tarefas numa fila (Redis; em memória no desenvolvimento). O worker lê cada PDF e, quando todas as partes de um processo estão prontas, faz **uma** extração do processo inteiro. Um vigia reenfileira PDFs que ficaram "presos". Há reenvio e exclusão por PDF.
CONCEITO	Processamento assíncrono, produtor/consumidor, retomada após falha, "claim" atômico para dois workers não pegarem o mesmo processo.
ONDE	`app/queue.py`, `app/worker.py`, `app/run_worker.py`
DIGA	"Se o computador cair no meio, o sistema retoma sozinho. E posso subir mais workers para ir mais rápido."

3 Leitura de PDF, OCR e qualidade do texto

PROBLEMA	Autos digitalizados antigos são imagens, ou trazem um texto embutido corrompido (letras cirílicas no lugar das latinas).
O QUE FAZ	PyMuPDF lê o texto. Se a página não tem texto útil, ou o texto parece lixo (detector de cirílico e de palavras comuns ausentes), o Tesseract em português refaz o OCR. Mede o tempo por página.
CONCEITO	PDF nato-digital x digitalizado, OCR, heurística de qualidade, leitura página a página (não carrega tudo na memória).
ONDE	`app/ingest/pdf.py`, `app/ingest/quality.py`
DIGA	"Não confiamos cegamente no texto do PDF: se ele parece corrompido, lemos a imagem de novo."

4 Citações: Evento (eproc), ID (PJe), VOL (físico)

PROBLEMA	Seu maior gargalo: ferramentas de IA confundem Evento com ID e com a página do ato.
O QUE FAZ	Detecta o sistema (rodapé “Num. X – Pág. N” = PJe; marcadores do eproc) e **monta o rótulo de cada trecho por código**: `Evento N, pg. P` ou `ID N, pg. P`. A IA só copia o rótulo. Lê também número, volume e página inicial pelo nome do arquivo.
CONCEITO	Expressões regulares, herança de marcador entre páginas, “não peça ao modelo o que o código sabe”.
ONDE	`app/ingest/citation.py`
DIGA	“A citação não vem da memória da IA: vem de uma tabela que o código montou.”

5 Linha do tempo do eproc (sem IA)

PROBLEMA	A cronologia dos atos é o que o analista mais usa, e a IA errava datas e inventava eventos.
O QUE FAZ	Lê as “páginas de separação” do eproc (2º grau e 1ª instância): nº do evento, data, movimento, usuário. Classifica a relevância (alta, média, baixa). A IA recebe o **índice completo** e o texto integral só dos atos relevantes; depois a cronologia escrita por ela é conferida (data corrigida, ordem, eventos inexistentes apontados).
CONCEITO	Fonte autoritativa x geração, redução de contexto por relevância, pós-validação.
ONDE	`app/ingest/eventos.py`, `app/extract.py` (`select_context_eventos`)
DIGA	“Reduzimos o texto enviado à IA e, ao mesmo tempo, ganhamos precisão: ela vê o mapa completo e lê só o que importa.”

6 Linha do tempo do PJe

PROBLEMA	O PJe não tem páginas de separação, e processos migrados trazem os autos físicos digitalizados como um único “Volume”.
O QUE FAZ	Lê a tabela “Documentos” da capa (ID, data, nome, tipo; o ID vem quebrado em duas linhas) e cruza com os rodapés “Num. ID – Pág.”. O Volume recebe o orçamento restante, priorizando as páginas mais recentes. A cronologia sai como `ID N, pg. P - data - ato` e é conferida.
CONCEITO	Adaptador por sistema: mesmo motor, fontes diferentes.
ONDE	`app/ingest/pje.py`, `tests/test_pje.py`
DIGA	“Cada sistema processual ganha um adaptador pequeno; o resto do sistema não muda. É assim que o projeto escala para outros tribunais.”

7 Busca híbrida (Elasticsearch)

PROBLEMA	Para o chat e para processos grandes, é preciso achar as páginas certas sem mandar tudo à IA.
O QUE FAZ	Indexa cada página com busca por palavras (BM25) e por vetor (embeddings locais de 256 dimensões) e combina as duas. Sem Elasticsearch, usa um índice em memória com a mesma interface.
CONCEITO	Busca lexical x semântica, embeddings, RAG, interface comum para trocar o motor.
ONDE	`app/search/` (`base.py`, `elastic.py`, `memory.py`)
DIGA	“Termos exatos como número de matrícula pedem busca por palavra; perguntas em linguagem natural pedem busca por significado. Usamos as duas.”

8 Extração por LLM com prompts do analista

PROBLEMA	Transformar o texto em campos da planilha, respeitando listas fechadas e o formato do analista.
O QUE FAZ	Escolhe o prompt pelo tipo/classe (execução fiscal, embargos, recursos, outras ações) e envia o contexto. A saída é um **JSON restrito ao esquema** da aba: listas fechadas (ex.: EXIT. GARANTIA) aceitam só valores permitidos; fora da lista vira “revisar”. Se o contexto passa do limite, registra o corte.
CONCEITO	Saída estruturada, esquema JSON, engenharia de prompt, orçamento de contexto, “nunca invente: use nulo”.
ONDE	`app/extract.py`, `prompts/*.md`, `app/schemas.py`
DIGA	“Os prompts são do analista, versionados em arquivo. Quem conhece o direito controla o conteúdo; o código controla o formato.”

9 Provedores de IA (Gemini e Anthropic)

PROBLEMA	Limites de uso, erros 503/429 e troca de modelos não podem quebrar o trabalho.
O QUE FAZ	Interface única para Gemini (padrão, AI Studio) e Anthropic. Novas tentativas com espera, modelo reserva, mensagens de erro em português e métricas de cada chamada (tokens, tentativas, espera, modelo).
CONCEITO	Padrão adaptador, *retry* com recuo exponencial, tolerância a falhas, observabilidade.
ONDE	`app/llm.py`, `app/config.py`
DIGA	“Trocar de provedor é mudar uma variável de ambiente. Não ficamos presos a um fornecedor.”

10 Validação: citações e cronologia

PROBLEMA	Em contexto jurídico, uma citação inventada é pior que nenhuma.
O QUE FAZ	Confere cada “Evento/ID/pg.” citado com as páginas realmente lidas e sinaliza as inválidas. Formata corresponsáveis como lista “Nome – CPF/CNPJ”. Confere a cronologia (seção 5 e 6).
CONCEITO	Verificação independente da saída do modelo (“confiar, mas conferir”).
ONDE	`app/extract.py` (`check_citations`, `format_corresponsaveis`)
DIGA	“O revisor vê um alerta quando a IA cita algo que não existe no PDF.”

11 Planilha modelo e exportação

PROBLEMA	Cada analista tem a sua planilha; o sistema não pode impor um layout.
O QUE FAZ	Lê o .xlsx do analista, reconhece colunas pelo texto do cabeçalho (normalizado), cadastra os processos da planilha, preenche **só células vazias**, acrescenta linhas novas, preserva as demais abas e avisa sobre colunas que não reconhece.
CONCEITO	Mapeamento por cabeçalho, escrita não destrutiva, openpyxl.
ONDE	`app/template.py`, `app/export.py`, `app/view.py`
DIGA	“O sistema se adapta à planilha do analista, e não o contrário. Nada que ele já digitou é sobrescrito.”

12 Revisão e chatbot com fontes

PROBLEMA	O analista precisa aprovar o resultado e tirar dúvidas sobre o processo.
O QUE FAZ	Cada processo tem situação (a revisar, revisado, erro…). Edições do analista são preservadas; “Refazer extração” descarta. O chat busca as páginas relevantes e responde citando a origem; a resposta pode ser adicionada às observações.
CONCEITO	Humano no circuito (*human-in-the-loop*), RAG com citação.
ONDE	`app/rag.py`, endpoint `/api/chat`, `static/app.js`
DIGA	“A IA propõe, o analista decide. Cada resposta traz a página de onde saiu.”

13 Planilha viva (front-end)

PROBLEMA	Um painel de cadastro e outro de resultados obrigava a ir e voltar.
O QUE FAZ	Tela única: tabela editável (70%) e assistente retrátil (30%). Tema claro/escuro, filtros, colunas e linhas redimensionáveis, janelas para textos longos, erros por PDF com “tentar novamente”.
CONCEITO	JavaScript sem framework, variáveis CSS para temas, `localStorage` para preferências.
ONDE	`static/index.html`, `static/app.css`, `static/app.js`
DIGA	“A interface parece o Excel que o analista já usa, com a IA do lado.”

14 Medições

PROBLEMA	Para convencer a direção e dimensionar custos, é preciso números e não impressões.
O QUE FAZ	Mostra tokens, páginas enviadas à IA, processos cortados, tempos de leitura/OCR/IA, tentativas e ritmo estimado, em cartões e barras.
CONCEITO	Observabilidade: medir antes de otimizar.
ONDE	`static/app.js` (`renderMed`), `app/worker.py` (`medidas`)
DIGA	“Com 30 processos medidos, projeto o volume por dia e o custo, sem chute.”

15 Empacotamento e testes

PROBLEMA	Rodar em qualquer máquina igual e garantir que mudanças não quebrem o que funciona.
O QUE FAZ	Docker Compose sobe API, worker, Redis e Elasticsearch com um comando. 80 testes automatizados usam uma IA simulada para testar o fluxo inteiro sem custo.
CONCEITO	Contêineres, ambiente reproduzível, testes com *mocks*.
ONDE	`Dockerfile`, `docker-compose.yml`, `tests/`
DIGA	“Cada regra que aprendemos com um processo real virou um teste, para não voltar a errar.”

3. Decisões de projeto e alternativas descartadas

Decisão	Por quê (e o que foi descartado)
Uma extração por processo	Juntar todas as partes e fazer 1 chamada dá visão completa e custa menos que uma chamada por PDF. Custo: o limite de contexto, tratado com índice + relevância.
Código monta as citações	Evita o erro Evento x ID. Alternativa descartada: pedir à IA que “descubra” o número.
Índice completo + texto só do relevante	Menos tokens e mais precisão que enviar tudo. Risco: classificar mal um ato; por isso existe o botão Eventos e a revisão.
Planilha do analista como modelo	Substituiu o cadastro por relatório do Mcfly: menos etapas e adapta-se a qualquer layout.
Embeddings locais (256d)	Zero custo e sem enviar dados a terceiros. Alternativa avaliada: EmbeddingGemma 2, só vale se as Medições mostrarem muitos processos cortados.
JavaScript simples no front	Sem build nem dependências; fácil de hospedar. Streamlit foi considerado e descartado pelo layout e pelo controle de interface.
Modelos Flash no teste	O nível gratuito dá quota zero aos modelos Pro e limites diários baixos aos Flash; por isso o ritmo do piloto é limitado pelo Google, e não pelo sistema.

4. Como escalar: Minas Gerais e depois o Brasil

Escalar é resolver **quatro problemas diferentes**. Trate-os separadamente.

4.1 Escala de volume (técnica)

Hoje (piloto)	Para Minas Gerais	Para o Brasil
SQLite em um arquivo	PostgreSQL gerenciado	PostgreSQL com réplicas e separação por região/unidade
PDFs em disco local	Armazenamento de objetos (com criptografia)	Idem, com política de retenção e descarte
1 worker	Vários workers por contêiner (autoescala)	Fila gerenciada e workers por região
Elasticsearch único	Cluster pequeno	Cluster dimensionado por volume; avaliar índices por unidade
Chave de API em arquivo	Cofre de segredos	Cofre + rotação automática
Medições na tela	Métricas e alertas (tempo de fila, erros, custo)	Painel nacional de qualidade e custo

Gargalos reais, nesta ordem: (1) limite de uso do provedor de IA (resolve-se com conta paga e cotas negociadas); (2) OCR dos digitalizados (resolve-se com mais workers e OCR em paralelo); (3) a revisão humana (o ganho vem de reduzir o tempo de conferência, e não de eliminar o analista).

4.2 Escala de sistemas processuais

O projeto já tem um adaptador para eproc e outro para PJe. Para cada novo sistema (e-SAJ, Projudi e outros), o trabalho é: (a) coletar 5 a 10 PDFs reais; (b) descobrir onde estão ID, data e tipo de cada ato; (c) escrever o adaptador e os testes; (d) ajustar a citação. Priorize pelos tribunais com mais processos da carteira. Verifique também se há integração oficial com os sistemas (hoje o fluxo é por PDF baixado) e se ela é permitida para a instituição.

4.3 Escala de governança (o que a direção vai perguntar)

- **LGPD e sigilo:** processos têm dados pessoais e, às vezes, segredo de justiça. É preciso base legal, acordo de tratamento de dados e garantia contratual de que o provedor de IA não usa os dados para treinar modelos. Não use o nível gratuito com processos reais.
- **Segurança:** login institucional (SSO), perfis por procuradoria, trilha de auditoria (quem revisou o quê), criptografia e backup.
- **Responsabilidade:** a IA nunca decide; o analista revisa e assina. Registrar a versão do prompt e do modelo usados em cada extração.
- **Onde rodar:** nuvem institucional, nuvem contratada ou infraestrutura própria. A escolha depende da área de TI e de segurança da instituição.

4.4 Escala de adoção (pessoas)

- **Piloto medido:** 20 a 30 processos com um “conjunto de referência” (relatórios já feitos à mão). Medir: acerto por campo, citações válidas, tempo por processo.
- **Campeões:** 2 a 3 analistas por unidade que validam prompts e listas fechadas.
- **Biblioteca de prompts versionada:** um dono por tipo de ação e revisão periódica.
- **Treinamento curto:** 1 hora de uso e 1 página de “quando não confiar” (digitalizados ruins, cortes, listas fechadas).

4.5 Roteiro

Etapa	Meta e critério para avançar
0. Piloto	Provar o ganho com números. Avança se o acerto e o tempo forem aceitos pelos analistas.
1. Minas Gerais	Produção segura (login, auditoria, infraestrutura gerenciada, conta paga). Avança com adoção estável e custo por processo conhecido.
2. Novos sistemas	Adaptadores por sistema, na ordem de volume da carteira.
3. Brasil	Implantação por regiões, painel nacional e equipe de suporte.

> **Atenção:** para propor isso à direção, leve três números do piloto: **tempo médio por processo**, **% de campos corretos sem edição** e **custo médio por processo**. Sem eles, “potencial enorme” vira opinião; com eles, vira argumento.

5. Portfólio: mostrar o projeto, usando IA, de forma pessoal e honesta

> **Primeiro, um cuidado:** este projeto nasceu de um trabalho real e lida com processos reais. Antes de publicar código, telas ou exemplos, confirme com a instituição o que pode ser divulgado. Nunca publique dados reais de processos, nomes de partes, números de processo nem capturas de tela com dados. Use processos sintéticos e anonimizados na demonstração.

5.1 Usar IA não é problema; esconder é

Hoje, recrutadores esperam que desenvolvedores usem IA. O que diferencia as pessoas é **julgamento**: saber o que pedir, avaliar, recusar e corrigir. Diga abertamente: "Construí com assistência de IA; as decisões, as regras de negócio e a validação foram minhas." Ser claro sobre isso é um ponto a favor.

5.2 O que torna o projeto seu

O que fazer	Por que funciona
Escreva o "porquê" de cada decisão	Um registro curto por decisão (ex.: "por que o código monta as citações"). Mostra raciocínio, que a IA não dá por você.
Destaque o conhecimento do domínio	Evento x ID, listas fechadas, relevância dos atos, critérios do analista. Poucos desenvolvedores conhecem a rotina da PGFN: é o seu diferencial.
Meça e mostre números	Tempo por processo, % de acerto contra o relatório manual, citações válidas. Números do piloto valem mais que adjetivos.
Conte os erros que você resolveu	Cota do Gemini, Elasticsearch caindo, texto corrompido, 503. Um "diário de bordo" de problemas e soluções prova autoria.
Reescreva uma parte à mão	Escolha um módulo (ex.: `parse_indice` do PJe) e refaça sem ajuda, com testes seus. Você vai poder explicar cada linha.
Escreva um teste seu	Um caso real anonimizado que você descobriu. É assinatura de quem entende o problema.
Crie um conjunto de referência	Compare a saída da IA com o seu gabarito. Mostrar avaliação é o que separa um demo de um sistema sério.
Faça um artigo ou vídeo de 5 minutos	"Como reduzi erros de citação em processos judiciais com IA." Sua voz e sua história.

5.3 Estrutura sugerida do portfólio

1. **Resumo em 3 linhas:** problema, solução, resultado (com números).
2. **Demonstração:** vídeo curto com processo sintético; diagrama de arquitetura.
3. **Decisões e trade-offs:** use a seção 3 deste guia como base.
4. **Qualidade:** testes, avaliação contra gabarito, medições.
5. **Limites e riscos:** LGPD, quando não confiar, o que ainda falta.
6. **Seu papel:** o que você decidiu e o que a IA gerou (uma tabela honesta).

5.4 Frases para currículo (troque pelos seus números)

- "Projetei e implementei, com apoio de IA, um sistema que extrai dados de processos judiciais (eproc/PJe) para planilha, com citações verificadas automaticamente."
- "Reduzi o tempo de análise por processo de **[X]** para **[Y]** minutos em piloto com **[N]** processos (medido)."
- "Construí avaliação contra gabarito: **[Z]%** dos campos corretos sem edição; **[W]%** das citações válidas."
- "Arquitetura assíncrona (Redis, workers), OCR, busca híbrida (Elasticsearch) e integração com Gemini, empacotada em Docker, com 80 testes automatizados."

5.5 Para entrevista: sabendo explicar

Treine explicar, sem olhar o código: (1) o fluxo de ponta a ponta; (2) por que o código monta as citações; (3) como a linha do tempo reduz tokens e erros; (4) o que acontece se o Gemini cair; (5) o que você mudaria para 100 vezes mais volume.

6. Perguntas que você vai receber

“A IA pode errar. Como vocês garantem confiança?”
Três camadas: citações montadas por código e conferidas com o PDF; datas e eventos validados contra o índice do sistema; revisão do analista antes de exportar. E há medição de acerto contra relatórios feitos à mão.

“E os dados sigilosos?”
Não se usa o nível gratuito com processos reais. Em produção: contrato que proíbe treinar modelos com os dados, controle de acesso, auditoria e, se necessário, infraestrutura da própria instituição.

“Quanto custa por processo?”
Depende do modelo e do tamanho do processo. A tela Medições mostra tokens por processo; multiplicando pelo preço vigente do modelo escolhido, chega-se ao custo. Apresente o número do piloto, e não uma estimativa.

“Quanto tempo economiza?”
Compare o tempo manual por processo (cronometre 10 processos) com o tempo de revisão assistida. Mostre também o tempo de máquina (OCR + IA), que roda sem o analista.

“E se o fornecedor de IA mudar ou sair do ar?”
Há interface única para provedores (Gemini e Anthropic), modelo reserva, novas tentativas e fila que retoma sozinha.

“Funciona com outros tribunais?”
Com adaptadores por sistema processual: eproc e PJe já existem. Cada novo sistema exige amostras reais e testes.

“O que você fez e o que a IA fez?”
Responda com a tabela “Seu papel” (seção 5.3, item 6). Exemplo: “A IA escreveu a primeira versão do código; eu defini as regras do analista, escolhi as decisões de arquitetura, validei com processos reais e escrevi os casos de teste.”

7. Glossário

Termo	Significado
RAG	Buscar os trechos relevantes e entregá-los à IA para que responda com base neles, citando a fonte.
Token	Pedaço de texto que a IA conta e cobra (em português, cerca de 2,5 caracteres por token nas medições).
Contexto	Quanto texto cabe em uma chamada à IA. Texto acima do limite é cortado.
OCR	Reconhecimento de texto a partir da imagem de uma página.
Embedding	Representação numérica do significado de um texto, usada na busca semântica.
BM25	Algoritmo clássico de busca por palavras.
Worker	Processo que pega tarefas da fila e as executa em segundo plano.
Fila (Redis)	Lista de tarefas pendentes, mantida fora da API.
Saída estruturada	Resposta da IA obrigada a seguir um esquema JSON.
Human-in-the-loop	O humano revisa e decide antes do resultado valer.
Eproc / PJe	Sistemas de processo eletrônico. O eproc identifica atos por Evento; o PJe, por ID de documento.
Rate limit	Limite de chamadas por minuto/dia imposto pelo provedor de IA.